

LAPORAN MACHINE LEARNING
Analisis Eksperimental Supervised Learning, Unsupervised Learning, dan
Prapemrosesan Data



Disusun Oleh:

Nama : Ali Akbar Bermano
NPM : G1A024041
Kelas : A

Dosen Pengampu :

Ir. Arie Vatesia, S.T., M.T.I., Ph.D., IPP.

PROGRAM STUDI INFORMATIKA
FAKULTAS TEKNIK
UNIVERSITAS BENGKULU
2026

BAB I

PENDAHULUAN

1.1 Latar Belakang

Machine Learning merupakan salah satu bidang dalam kecerdasan buatan yang memungkinkan komputer mempelajari pola dari data dan menghasilkan suatu keluaran berdasarkan pola yang ditemukan. Dalam penerapannya, keberhasilan suatu metode Machine Learning tidak hanya bergantung pada algoritma yang digunakan, tetapi juga pada bagaimana data dipersiapkan dan dianalisis sebelum diberikan kepada model. Karakteristik data seperti perbedaan skala antarfitur, jumlah dimensi yang tinggi, keberadaan noise, serta bentuk distribusi data dapat memengaruhi hasil pemodelan secara signifikan.

Salah satu tahapan penting dalam pengolahan data adalah preprocessing. Data dengan fitur yang memiliki rentang nilai berbeda dapat menyebabkan beberapa algoritma memberikan perhatian yang lebih besar terhadap fitur dengan skala tertentu. Oleh karena itu, diperlukan teknik transformasi atau scaling agar data berada pada skala yang lebih sesuai. Pada analisis ini digunakan beberapa teknik preprocessing, yaitu StandardScaler, RobustScaler, MinMaxScaler, dan Normalizer. Perbandingan teknik tersebut digunakan untuk memahami bagaimana transformasi data dapat memengaruhi karakteristik data dan performa algoritma Machine Learning.

Selain preprocessing, data Machine Learning sering memiliki jumlah fitur yang cukup banyak. Dimensi yang tinggi dapat menyulitkan proses visualisasi, meningkatkan kompleksitas komputasi, serta menyebabkan informasi yang terdapat pada data menjadi sulit untuk dianalisis secara langsung. Salah satu pendekatan yang dapat digunakan untuk mengatasi permasalahan tersebut adalah reduksi dimensi. Dalam project ini, reduksi dimensi dianalisis menggunakan Principal Component Analysis (PCA) dan Non-negative Matrix Factorization (NMF). PCA digunakan untuk memperoleh representasi data berdasarkan komponen utama, termasuk dalam analisis citra wajah melalui pendekatan *Eigenfaces*. Sementara itu, NMF digunakan untuk menganalisis representasi komponen yang bersifat non-negatif, termasuk pada kasus pemisahan sumber sinyal.

Permasalahan lain muncul ketika data tidak memiliki label kelas sehingga metode supervised learning tidak dapat digunakan secara langsung. Dalam kondisi tersebut, pendekatan unsupervised learning dapat digunakan untuk menemukan pola atau struktur yang terdapat di dalam data. Salah satu bentuk unsupervised learning yang dianalisis dalam project ini adalah clustering, yaitu proses mengelompokkan data berdasarkan kemiripan karakteristiknya. Tiga algoritma clustering yang digunakan adalah K-Means, Agglomerative Clustering, dan DBSCAN.

Ketiga algoritma tersebut memiliki pendekatan yang berbeda dalam membentuk kelompok data. K-Means melakukan pengelompokan berdasarkan pusat cluster,

Agglomerative Clustering membangun struktur cluster secara hierarkis, sedangkan DBSCAN mengelompokkan data berdasarkan kepadatan dan mampu mengidentifikasi data yang dianggap sebagai noise. Perbedaan karakteristik tersebut menjadi penting untuk dianalisis, terutama ketika algoritma diterapkan pada data dengan bentuk cluster yang berbeda.

Dalam project ini, analisis clustering juga dilakukan menggunakan dataset Two Moons yang memiliki struktur cluster non-konveks. Dataset tersebut digunakan untuk melihat bagaimana bentuk dan struktur data dapat memengaruhi hasil pengelompokan. Berdasarkan hasil eksperimen, DBSCAN setelah data distandardisasi mampu memperoleh Adjusted Rand Index (ARI) sebesar 1,00 pada dataset Two Moons, sementara K-Means dan Agglomerative Clustering mengalami kesulitan dalam memisahkan cluster yang memiliki bentuk non-konveks.


Selain clustering, analisis juga mencakup penggunaan t-SNE untuk membantu memvisualisasikan data berdimensi tinggi. Pada dataset Digits, t-SNE digunakan untuk melihat struktur kelompok data dalam representasi dua dimensi. Pendekatan ini memberikan sudut pandang visual terhadap hubungan antar-data yang sulit diamati ketika data masih berada dalam dimensi aslinya.

Berdasarkan keseluruhan eksperimen tersebut, analisis ini dilakukan untuk memahami hubungan antara karakteristik data, preprocessing, reduksi dimensi, visualisasi, serta pemilihan algoritma clustering. Dengan melakukan beberapa eksperimen pada dataset yang berbeda, dapat diamati bahwa metode Machine Learning memiliki karakteristik dan kondisi penggunaan masing-masing. Oleh karena itu, pemilihan metode perlu mempertimbangkan karakteristik data dan tujuan analisis yang ingin dicapai.

BAB II

METODOLOGI DAN OUTPUT EKSPERIMEN

2.1. penerapan beberapa metode *scaling*




Gambar tersebut menunjukkan perbandingan kondisi data sebelum dan sesudah dilakukan beberapa teknik preprocessing, yaitu **StandardScaler**, **MinMaxScaler**, **RobustScaler**, dan **Normalizer**. Pada bagian *Original Data*, terlihat bahwa data memiliki rentang nilai yang cukup besar dengan dua kelompok utama, yaitu titik berwarna merah dan biru. Setelah dilakukan preprocessing, skala dan distribusi data mengalami perubahan sesuai dengan karakteristik masing-masing metode, tetapi pola pemisahan antara kedua kelompok masih dapat diamati.

Pada **StandardScaler**, data ditransformasikan sehingga pusat distribusinya berada di sekitar nilai nol. Hal ini terlihat dari titik-titik data yang tersebar pada nilai positif dan negatif di sekitar sumbu koordinat. **MinMaxScaler** mengubah skala data sehingga nilainya berada pada rentang yang lebih kecil dan seragam. Pada hasilnya, sebagian besar titik berada pada rentang sekitar 0 hingga 1, dengan kelompok merah tetap berada di atas kelompok biru. Sementara itu, **RobustScaler** melakukan penskalaan berdasarkan median dan rentang interkuartil, sehingga hasil transformasinya tetap mempertahankan pola data dengan pengaruh nilai ekstrem yang lebih terkendali.

Berbeda dari ketiga metode tersebut, **Normalizer** melakukan normalisasi berdasarkan masing-masing sampel. Akibatnya, bentuk distribusi data terlihat berbeda dibandingkan hasil

scaling lainnya, dengan titik-titik terkonsentrasi pada area yang lebih sempit. Secara keseluruhan, gambar menunjukkan bahwa setiap metode preprocessing menghasilkan representasi skala data yang berbeda. Perbedaan ini penting karena skala fitur dapat memengaruhi proses pembelajaran dan performa algoritma machine learning yang digunakan pada tahap berikutnya.

2.2. Pengaruh Scaling yang Tepat terhadap Data Training dan Testing




Gambar tersebut menunjukkan perbandingan antara **data asli**, **data yang telah diskalakan dengan benar**, dan **data yang mengalami scaling secara tidak tepat**. Pada *Original Data*, data training ditunjukkan dengan titik biru, sedangkan data testing ditunjukkan dengan segitiga merah. Data memiliki rentang nilai yang cukup besar pada kedua fitur, sehingga diperlukan proses scaling agar skala setiap fitur menjadi lebih seragam sebelum digunakan dalam proses pemodelan.

Pada bagian **Scaled Data**, data telah ditransformasikan ke dalam rentang yang lebih teratur, yaitu sekitar 0 hingga 1. Data training dan testing tetap berada pada ruang skala yang sama sehingga posisi data testing masih dapat dibandingkan secara konsisten dengan data training. Hal ini menunjukkan bahwa proses scaling perlu diterapkan secara konsisten terhadap kedua kelompok data. Dalam penerapannya, parameter scaling seharusnya diperoleh dari data training dan kemudian digunakan untuk mentransformasikan data testing.

Sementara itu, bagian **Improperly Scaled Data** menunjukkan kondisi ketika scaling dilakukan secara tidak tepat sehingga posisi data testing berubah dan tidak lagi berada pada skala yang konsisten dengan data training. Perbedaan posisi segitiga merah dibandingkan

dengan *Scaled Data* menunjukkan bahwa data training dan testing tidak ditransformasikan menggunakan dasar skala yang sama. Kondisi tersebut dapat menyebabkan model menerima data dengan representasi yang berbeda antara tahap pelatihan dan pengujian, sehingga dapat memengaruhi hasil evaluasi model. Oleh karena itu, proses scaling harus dilakukan dengan **fit pada data training**, kemudian transformasi yang sama diterapkan pada data testing.

2.3. Reduksi Dimensi Menggunakan Principal Component Analysis (PCA)



Gambar tersebut menunjukkan proses **reduksi dimensi menggunakan Principal Component Analysis (PCA)**. Pada bagian **Original Data**, terlihat data awal yang memiliki dua fitur, yaitu *feature 1* dan *feature 2*. Dua arah yang ditunjukkan sebagai **Component 1** dan


Component 2 merupakan komponen utama yang diperoleh PCA. Component 1 menunjukkan arah dengan variasi data terbesar, sedangkan Component 2 menunjukkan arah variasi berikutnya yang saling tegak lurus terhadap Component 1.


Pada bagian **Transformed Data**, data asli telah ditransformasikan ke dalam ruang komponen utama. Sumbu horizontal merupakan **First principal component**, sedangkan sumbu vertikal merupakan **Second principal component**. Hasil transformasi menunjukkan bahwa sebagian besar variasi data dapat direpresentasikan sepanjang komponen pertama, sementara komponen kedua memberikan variasi tambahan yang lebih kecil. Transformasi ini memungkinkan data dengan dua fitur awal direpresentasikan berdasarkan komponen yang paling informatif.

Bagian **Transformed data w/ second component dropped** menunjukkan kondisi ketika **komponen utama kedua dihilangkan**. Seluruh data kemudian hanya direpresentasikan menggunakan *First principal component*, sehingga titik-titik data berada pada satu garis dengan nilai komponen kedua sama dengan nol. Proses ini merupakan bentuk reduksi dimensi karena data yang awalnya memiliki dua dimensi direpresentasikan hanya menggunakan satu komponen utama. Meskipun informasi dari komponen kedua hilang, sebagian besar pola data masih dapat dipertahankan melalui komponen pertama.

Pada bagian **Back-rotation using only first component**, data dikembalikan ke ruang fitur awal menggunakan hanya komponen pertama. Hasilnya menunjukkan bahwa titik-titik data membentuk pola sepanjang arah utama data pada ruang fitur awal. Karena komponen kedua sebelumnya dihilangkan, hasil rekonstruksi tidak sepenuhnya sama dengan data asli. Hal tersebut menunjukkan adanya sebagian informasi yang hilang akibat proses reduksi dimensi. Secara keseluruhan, gambar ini memperlihatkan bagaimana PCA dapat digunakan untuk mengubah representasi data, mengurangi jumlah dimensi, serta mempertahankan komponen yang memiliki variasi terbesar dalam data.

2.4. Analisis Distribusi Fitur pada Dataset Breast Cancer






Gambar tersebut menunjukkan distribusi **30 fitur pada dataset Breast Cancer Wisconsin** yang dibedakan berdasarkan dua kelas, yaitu **malignant** dan **benign**. Setiap grafik merupakan histogram yang menggambarkan frekuensi nilai dari suatu fitur tertentu. Warna biru menunjukkan data pada kelas *malignant*, sedangkan warna hijau menunjukkan kelas *benign*. Fitur-fitur yang ditampilkan terbagi menjadi tiga kelompok utama, yaitu nilai rata-rata (*mean*), nilai kesalahan (*error*), dan nilai terburuk (*worst*) dari karakteristik sel, seperti radius, tekstur, perimeter, area, kekompakan, kecekungan, simetri, dan *fractal dimension*.

Berdasarkan distribusi pada gambar, beberapa fitur menunjukkan **perbedaan distribusi yang cukup jelas antara kelas malignant dan benign**. Contohnya adalah *mean radius*, *mean perimeter*, *mean area*, *worst radius*, *worst perimeter*, dan *worst area*, di mana distribusi kelas malignant cenderung berada pada nilai yang lebih tinggi dibandingkan kelas benign. Hal ini menunjukkan bahwa fitur-fitur tersebut memiliki pola yang berbeda antar kelas dan berpotensi memberikan informasi yang berguna dalam membedakan kedua jenis diagnosis. Namun, terdapat pula fitur yang distribusinya cukup banyak mengalami tumpang tindih antara kedua kelas, seperti beberapa fitur *error* dan *fractal dimension*, sehingga fitur tersebut secara visual tidak menunjukkan pemisahan kelas yang sejelas fitur lainnya.

Visualisasi ini juga memperlihatkan bahwa setiap fitur memiliki **rentang nilai dan skala yang berbeda-beda**. Sebagai contoh, *mean area* memiliki rentang nilai yang jauh lebih besar dibandingkan *mean smoothness*, sedangkan beberapa fitur *error* memiliki rentang yang relatif kecil. Perbedaan skala tersebut menjadi salah satu alasan penting dilakukannya **preprocessing atau scaling** sebelum data digunakan dalam algoritma machine learning. Dengan demikian, histogram ini memberikan gambaran awal mengenai karakteristik distribusi fitur serta menunjukkan bahwa terdapat perbedaan skala dan pola antarfitur yang perlu diperhatikan pada tahap analisis dan pemodelan selanjutnya.

2.5. Visualisasi PCA pada Dataset Breast Cancer




Gambar tersebut menunjukkan hasil reduksi dimensi menggunakan **Principal Component Analysis (PCA)** pada dataset *Breast Cancer*. Data yang awalnya memiliki banyak fitur direpresentasikan ke dalam dua komponen utama, yaitu **First principal component** pada sumbu horizontal dan **Second principal component** pada sumbu vertikal. Titik berbentuk lingkaran berwarna biru menunjukkan kelas **malignant**, sedangkan titik berbentuk segitiga berwarna oranye menunjukkan kelas **benign**.

Berdasarkan visualisasi, kedua kelas menunjukkan pola distribusi yang berbeda pada ruang dua komponen utama. Data **benign** cenderung terkonsentrasi pada wilayah dengan nilai *First principal component* yang lebih rendah, sedangkan data **malignant** lebih banyak berada pada wilayah dengan nilai *First principal component* yang lebih tinggi. Meskipun demikian, masih terdapat sejumlah titik dari kedua kelas yang saling berdekatan atau mengalami tumpang tindih, terutama di sekitar bagian tengah grafik. Hal ini menunjukkan bahwa dua komponen utama dapat memberikan gambaran mengenai perbedaan kedua kelas, tetapi belum sepenuhnya memisahkan seluruh data.

Visualisasi ini menunjukkan salah satu manfaat PCA, yaitu **mereduksi jumlah dimensi data sekaligus mempertahankan pola utama yang terdapat dalam data**. Dengan merepresentasikan data ke dalam dua komponen utama, hubungan dan distribusi antar kelas dapat lebih mudah diamati secara visual. Hasil ini juga menjadi dasar untuk melihat bahwa PCA dapat digunakan sebagai teknik reduksi dimensi sebelum dilakukan analisis atau pemodelan machine learning lebih lanjut.

2.6. Interpretasi Komponen Utama pada PCA




Gambar tersebut menunjukkan **kontribusi setiap fitur terhadap dua komponen utama (Principal Components) yang dihasilkan oleh PCA** pada dataset *Breast Cancer*. Baris pertama menunjukkan **First component**, sedangkan baris kedua menunjukkan **Second component**. Setiap kolom merepresentasikan salah satu dari 30 fitur yang digunakan dalam dataset. Nilai kontribusi ditunjukkan melalui gradasi warna pada skala di sebelah kanan, di mana warna dengan nilai lebih tinggi menunjukkan kontribusi positif yang lebih besar, sedangkan warna dengan nilai lebih rendah menunjukkan kontribusi negatif.

Pada **First component**, sebagian besar fitur memiliki nilai kontribusi positif, meskipun besar kontribusinya berbeda-beda. Fitur seperti *mean radius*, *mean perimeter*, *mean area*, *mean concavity*, serta beberapa fitur *worst* terlihat memiliki kontribusi yang relatif besar terhadap komponen pertama. Hal ini menunjukkan bahwa komponen pertama banyak merepresentasikan karakteristik utama yang berkaitan dengan ukuran dan bentuk sel. Sementara itu, pada **Second component**, terdapat kombinasi kontribusi positif dan negatif yang lebih beragam. Beberapa fitur memiliki kontribusi positif yang relatif tinggi, sedangkan fitur lainnya memberikan kontribusi negatif.

Visualisasi ini membantu menjelaskan bagaimana PCA membentuk komponen utama dari kombinasi seluruh fitur asli. Setiap komponen merupakan kombinasi linear dari fitur-fitur tersebut dengan bobot tertentu. Dengan demikian, grafik ini menunjukkan fitur mana yang memberikan kontribusi lebih besar atau lebih kecil dalam membentuk masing-masing komponen utama. Informasi tersebut dapat digunakan untuk memahami karakteristik data

setelah dilakukan reduksi dimensi dan membantu menginterpretasikan hasil visualisasi PCA sebelumnya.

2.7. Transformasi Data dengan PCA dan Whitening




Gambar tersebut menunjukkan perbandingan antara **data asli (Original Data)** dan **data yang telah melalui proses whitening (Whitened Data)**. Pada data asli, terlihat bahwa titik-titik data membentuk pola memanjang secara diagonal dari kiri atas ke kanan bawah. Pola tersebut menunjukkan adanya hubungan yang kuat antara kedua fitur, sehingga variasi data masih memiliki arah tertentu dan belum tersebar secara independen.

Setelah dilakukan proses **whitening**, data ditransformasikan ke dalam ruang komponen utama yang terdiri dari **First principal component** dan **Second principal component**. Pada hasil transformasi, pola diagonal pada data asli tidak lagi terlihat. Data menjadi lebih tersebar pada kedua arah komponen utama, sehingga korelasi antar komponen dikurangi dan masing-masing komponen memiliki skala yang lebih seragam. Hal ini menunjukkan bahwa whitening tidak hanya melakukan transformasi ke ruang PCA, tetapi juga menyesuaikan skala komponen sehingga struktur data menjadi lebih terstandarisasi.

Perbandingan kedua grafik menunjukkan bahwa proses whitening mengubah representasi data secara signifikan. Data asli memiliki pola yang sangat terarah, sedangkan data hasil whitening memiliki penyebaran yang lebih seimbang pada kedua komponen utama. Transformasi ini dapat membantu algoritma atau analisis selanjutnya ketika diperlukan data dengan komponen yang memiliki skala lebih seragam dan korelasi yang lebih rendah.

2.8 Eigenfaces dengan Principal Component Analysis (PCA)



Dataset yang digunakan pada eksperimen ini adalah **Labeled Faces in the Wild (LFW)**, yaitu dataset gambar wajah yang digunakan untuk eksperimen pengolahan citra dan *machine learning*. Berdasarkan sumber notebook, dataset LFW yang digunakan terdiri dari **3.023 gambar dengan 62 kelas/orang**, dengan gambar wajah berukuran **250 × 250 piksel**. Pada proses eksperimen, pengunduhan dataset LFW menggunakan `fetch_lfw_people()` mengalami kendala pada beberapa *mirror*, sehingga digunakan **cache dataset LFW yang tersedia pada lingkungan Google Colab/Kaggle** sebagai jalur alternatif.


Gambar di atas menunjukkan hasil penerapan **Principal Component Analysis (PCA)** pada dataset LFW untuk menghasilkan representasi yang disebut **Eigenfaces**. Setiap gambar yang ditampilkan merupakan satu *principal component* yang telah dikembalikan ke bentuk gambar wajah. Pada gambar tersebut terdapat 15 komponen utama, mulai dari **1. component** hingga **15. component**. PCA bekerja dengan mencari pola variasi terbesar dari seluruh gambar wajah, kemudian merepresentasikan variasi tersebut dalam sejumlah komponen utama. Karena gambar wajah memiliki jumlah piksel yang sangat banyak, penggunaan PCA dapat membantu mengurangi dimensi data tanpa harus mempertahankan seluruh piksel sebagai fitur terpisah.

Setiap **Eigenface** tidak merepresentasikan satu wajah tertentu, tetapi menunjukkan pola visual yang berkontribusi terhadap variasi wajah dalam dataset. Perbedaan gradasi warna pada setiap komponen menunjukkan besarnya kontribusi atau bobot piksel terhadap komponen tersebut. Pada komponen pertama, pola wajah secara umum terlihat lebih jelas dibandingkan

beberapa komponen berikutnya. Komponen-komponen selanjutnya menampilkan pola yang semakin spesifik, seperti perubahan pada bagian wajah, rambut, latar belakang, atau area tertentu pada gambar. Dengan demikian, 15 Eigenfaces tersebut dapat digunakan sebagai representasi berdimensi lebih rendah dari gambar wajah asli.

Hasil ini menunjukkan bahwa PCA dapat digunakan untuk **kompresi dan ekstraksi fitur pada data gambar berdimensi tinggi**. Daripada menggunakan seluruh piksel gambar sebagai fitur, data wajah dapat direpresentasikan menggunakan sejumlah komponen utama yang menangkap variasi penting dalam dataset. Pendekatan ini dapat mengurangi kompleksitas data dan menjadi dasar untuk proses lanjutan seperti klasifikasi atau analisis wajah. Eksperimen Eigenfaces ini merupakan salah satu penerapan PCA yang dibahas dalam analisis reduksi dimensi pada dataset LFW.

2.9. Visualisasi PCA pada Dataset Digits




Gambar tersebut menunjukkan hasil reduksi dimensi menggunakan **Principal Component Analysis (PCA) pada dataset Digits**. Dataset Digits merupakan dataset yang berisi gambar angka tulisan tangan dan dalam eksperimen ini digunakan untuk melihat bagaimana data berdimensi tinggi dapat direpresentasikan dalam ruang dua dimensi. Setiap gambar direpresentasikan menggunakan fitur piksel, kemudian PCA digunakan untuk mengubah fitur tersebut menjadi beberapa komponen utama. Pada visualisasi ini, sumbu horizontal menunjukkan **First principal component**, sedangkan sumbu vertikal menunjukkan **Second principal component**.

Setiap titik pada grafik merepresentasikan satu sampel gambar angka, sedangkan **perbedaan warna dan bentuk marker menunjukkan kelas angka yang berbeda**. Terlihat bahwa sebagian besar titik dari berbagai kelas berada pada area yang saling berdekatan dan mengalami tumpang tindih. Meskipun terdapat beberapa kelompok titik yang cenderung memiliki posisi berbeda, dua komponen utama yang digunakan pada visualisasi ini belum menghasilkan pemisahan kelas yang sangat jelas. Hal tersebut menunjukkan bahwa ketika data Digits yang memiliki banyak fitur direduksi hanya menjadi dua komponen PCA, sebagian informasi mengenai perbedaan antar kelas masih hilang atau tidak dapat direpresentasikan secara sempurna dalam dua dimensi.

Visualisasi ini menunjukkan fungsi PCA sebagai teknik **reduksi dimensi sekaligus visualisasi data berdimensi tinggi**. Dengan hanya menggunakan dua komponen utama, data yang semula memiliki banyak fitur dapat divisualisasikan dalam sebuah grafik dua dimensi sehingga pola umum dan tingkat tumpang tindih antar kelas dapat diamati. Dalam analisis selanjutnya, hasil visualisasi PCA ini dapat dibandingkan dengan **t-SNE**, yang pada dataset Digits digunakan untuk melihat apakah struktur kelompok data dapat divisualisasikan dengan pemisahan yang lebih jelas.

2.10. Non-Negative Matrix Factorization (NMF)



Gambar tersebut menunjukkan hasil penerapan **Non-Negative Matrix Factorization (NMF)** dengan menggunakan dua komponen dan satu komponen. Pada bagian **NMF with two components**, data direpresentasikan menggunakan dua komponen yang digambarkan melalui dua arah panah. Kedua komponen tersebut digunakan untuk merepresentasikan variasi yang terdapat pada data asli. Dengan dua komponen, informasi data dapat direpresentasikan melalui dua arah yang berbeda sehingga struktur data masih dapat diamati dalam ruang dua dimensi.

Pada bagian **NMF with one component**, hanya satu komponen yang digunakan untuk merepresentasikan data. Satu komponen tersebut menjadi arah utama representasi data, sehingga model memiliki representasi yang lebih sederhana dibandingkan penggunaan dua komponen. Meskipun jumlah komponen dikurangi, pola umum persebaran data masih dapat diamati. Perbandingan kedua grafik menunjukkan bahwa penambahan jumlah komponen

memberikan lebih banyak arah untuk merepresentasikan struktur data, sedangkan penggunaan satu komponen menghasilkan representasi yang lebih sederhana dengan informasi yang lebih terbatas.

NMF bekerja dengan melakukan faktorisasi matriks menjadi komponen-komponen yang **bersifat non-negatif**, sehingga hasil komponennya dapat diinterpretasikan sebagai kombinasi aditif dari bagian-bagian data. Dalam konteks gambar tersebut, proses NMF digunakan untuk melihat bagaimana data dapat direpresentasikan menggunakan sejumlah komponen yang lebih sedikit. Dengan demikian, eksperimen ini memperlihatkan penggunaan NMF sebagai salah satu teknik **reduksi dimensi dan ekstraksi komponen** dari data.

2.11. Ekstraksi Komponen Wajah Menggunakan Non-Negative Matrix Factorization (NMF)



Gambar tersebut menunjukkan hasil **Non-Negative Matrix Factorization (NMF)** yang diterapkan pada dataset **Labeled Faces in the Wild (LFW)** untuk mengekstraksi pola atau komponen dari citra wajah. Hasil NMF ditampilkan dalam bentuk 15 komponen, mulai dari **0. component** hingga **14. component**. Setiap komponen direpresentasikan sebagai citra grayscale, di mana area yang lebih terang menunjukkan nilai komponen yang lebih tinggi, sedangkan area gelap menunjukkan nilai yang lebih rendah. Karena NMF bekerja dengan nilai non-negatif, komponen yang dihasilkan dapat dipandang sebagai bagian-bagian atau pola visual yang membentuk citra wajah.

Dari hasil visualisasi, setiap komponen menangkap pola yang berbeda pada citra wajah. **Komponen pertama** terlihat memiliki pola wajah yang cukup jelas dengan area terang yang dominan pada bagian wajah, sedangkan komponen-komponen berikutnya menangkap variasi pada bagian tertentu, seperti area rambut, sisi wajah, pakaian, atau latar belakang. Semakin banyak komponen yang digunakan, semakin banyak pola atau variasi visual yang dapat direpresentasikan dari dataset. Hal ini menunjukkan bahwa NMF tidak hanya menghasilkan representasi berdimensi lebih rendah, tetapi juga dapat menghasilkan komponen yang memiliki interpretasi visual.

Berbeda dengan hasil **Eigenfaces menggunakan PCA** yang telah ditampilkan sebelumnya, komponen NMF bersifat **non-negatif**, sehingga pola yang dihasilkan berupa kombinasi aditif dari bagian-bagian citra tanpa bobot negatif. Karakteristik tersebut membuat NMF sesuai untuk data seperti citra yang secara alami memiliki nilai piksel non-negatif. Dengan demikian, visualisasi ini memperlihatkan bagaimana NMF dapat digunakan untuk mengekstraksi pola wajah dari dataset LFW dan merepresentasikan informasi citra menggunakan sejumlah komponen yang lebih sederhana.

2.12. Visualisasi Gambar dengan Nilai Komponen NMF Terbesar




Gambar tersebut menunjukkan beberapa citra dari dataset **Labeled Faces in the Wild (LFW)** yang memiliki nilai tinggi pada **komponen NMF ke-7 (Large component 7)**. Setiap gambar merepresentasikan sampel wajah yang memiliki kontribusi relatif besar terhadap komponen tersebut. Berbeda dengan visualisasi komponen NMF sebelumnya yang memperlihatkan pola atau *basis component*, gambar ini menunjukkan **contoh data asli** yang memiliki nilai besar pada suatu komponen hasil NMF.

Terlihat bahwa gambar-gambar yang dipilih berasal dari individu dan kondisi gambar yang berbeda, tetapi memiliki pola visual tertentu yang membuatnya memiliki nilai tinggi pada

komponen ke-7. Kesamaan tersebut dapat berupa karakteristik umum pada citra, seperti posisi wajah, pencahayaan, latar belakang, atau pola visual lainnya yang ditangkap oleh komponen NMF. Dengan demikian, komponen ke-7 dapat dianggap sebagai salah satu pola laten yang digunakan NMF untuk merepresentasikan variasi pada kumpulan gambar wajah.

Visualisasi ini membantu menghubungkan **komponen NMF dengan data asli**. Jika visualisasi sebelumnya menunjukkan pola yang dipelajari oleh masing-masing komponen, gambar ini memperlihatkan contoh citra yang paling kuat direpresentasikan oleh komponen tertentu. Hal tersebut membuat hasil NMF lebih mudah diinterpretasikan karena komponen yang dihasilkan dapat dikaitkan secara langsung dengan contoh gambar dalam dataset.

2.13. Pemisahan Sumber Sinyal Menggunakan NMF




Gambar tersebut menunjukkan hasil visualisasi **tiga sumber sinyal sintetis** yang digunakan dalam eksperimen *blind source separation* menggunakan **Non-Negative Matrix Factorization (NMF)**. Sumbu horizontal menunjukkan **waktu**, sedangkan sumbu vertikal menunjukkan **nilai sinyal**. Tiga kurva dengan warna berbeda merepresentasikan tiga sinyal sumber yang memiliki pola perubahan berbeda sepanjang waktu. Ketiga sinyal tersebut memiliki karakteristik yang berulang dan saling tumpang tindih pada beberapa bagian, sehingga proses pemisahan sumber diperlukan untuk mengidentifikasi pola masing-masing sinyal.

Eksperimen ini merupakan penerapan NMF pada **data sintetis dengan tiga komponen sumber**. Tujuannya adalah melihat kemampuan NMF dalam melakukan pemisahan sumber sinyal yang bercampur (*blind source separation*). NMF melakukan faktorisasi data menjadi beberapa komponen non-negatif sehingga pola dasar yang terdapat pada sinyal dapat direpresentasikan melalui komponen-komponen tersebut. Sifat non-negatif ini sesuai dengan karakteristik sinyal yang digunakan dalam eksperimen.

Visualisasi tersebut menunjukkan bahwa data memiliki pola sinyal yang berubah terhadap waktu dan terdiri dari beberapa sumber yang berbeda. Hasil eksperimen NMF kemudian digunakan untuk memisahkan sumber-sumber tersebut berdasarkan pola yang terkandung di dalam data. Dalam konteks analisis, eksperimen ini menunjukkan bahwa **NMF dapat digunakan untuk ekstraksi dan pemisahan komponen pada data sinyal**, khususnya ketika data memiliki sifat aditif dan bernilai non-negatif. Sumber analisis menyatakan bahwa pada kasus pemisahan sumber sinyal sintetis ini, NMF lebih sesuai dibandingkan PCA karena komponen NMF bersifat non-negatif dan lebih cocok untuk merepresentasikan sifat aditif sinyal.

2.14. Perbandingan Hasil Pemisahan Sinyal Menggunakan NMF dan PCA




Gambar tersebut menunjukkan perbandingan proses **blind source separation** pada tiga sumber sinyal sintetis menggunakan **NMF dan PCA**. Grafik pertama, **Observations (first three measurements)**, menunjukkan tiga sinyal hasil pengamatan yang merupakan campuran dari sumber-sumber sinyal. Ketiga sinyal memiliki pola yang saling beririsan sehingga sumber asli belum dapat diamati secara langsung. Grafik kedua, **True sources**, menunjukkan tiga sumber sinyal sebenarnya yang digunakan sebagai acuan dalam eksperimen. Ketiga sumber memiliki pola perubahan terhadap waktu yang berbeda, sehingga dapat digunakan untuk melihat sejauh mana metode pemisahan mampu mengembalikan pola sumber asli.

Pada grafik ketiga, **NMF recovered signals**, terlihat hasil pemisahan sinyal menggunakan **Non-Negative Matrix Factorization (NMF)**. Ketiga sinyal hasil rekonstruksi memiliki pola yang relatif menyerupai pola pada *True sources*, meskipun terdapat beberapa perbedaan pada bentuk dan urutan pola. Hal ini menunjukkan bahwa NMF mampu menangkap komponen-komponen dasar yang terdapat dalam sinyal campuran. Sementara itu, grafik keempat, **PCA recovered signals**, menunjukkan hasil pemisahan menggunakan PCA. Pola yang dihasilkan PCA terlihat berbeda dari sumber asli dan beberapa sinyal masih menunjukkan pola yang bercampur atau tidak mengikuti karakteristik sumber sebenarnya secara konsisten.

Perbandingan tersebut menunjukkan bahwa **NMF memberikan hasil pemisahan yang lebih sesuai dengan karakteristik sumber sinyal pada eksperimen ini dibandingkan PCA**.


Hal ini berkaitan dengan sifat NMF yang menghasilkan komponen non-negatif dan merepresentasikan data sebagai kombinasi aditif dari beberapa komponen. Sebaliknya, PCA berfokus pada pencarian arah dengan variasi terbesar sehingga komponen yang diperoleh tidak secara khusus diarahkan untuk memisahkan sumber sinyal. Dengan demikian, eksperimen ini memperlihatkan penggunaan NMF untuk *blind source separation* serta perbedaannya dengan PCA dalam merekonstruksi sumber sinyal sintetis.

2.15 Visualisasi Dataset Digits




Gambar tersebut menampilkan beberapa contoh citra dari **dataset Digits** dalam bentuk grayscale (tingkat keabuan). Setiap citra merepresentasikan tulisan tangan angka yang ditampilkan berdasarkan nilai piksel, sehingga bagian berwarna putih menunjukkan piksel dengan intensitas lebih tinggi, sedangkan bagian hitam menunjukkan intensitas lebih rendah. Visualisasi ini digunakan untuk memberikan gambaran awal mengenai bentuk dan karakteristik data gambar angka sebelum dilakukan proses analisis lebih lanjut. Pada project ini, dataset Digits digunakan dalam penerapan **Principal Component Analysis (PCA)** dan **t-SNE** untuk melihat struktur data serta pemisahan kelas secara visual. PCA dua komponen menghasilkan visualisasi dengan beberapa kelas angka yang masih saling bertumpuk, sedangkan t-SNE mampu menampilkan kelompok angka yang lebih terpisah secara visual. Dengan demikian, gambar ini menjadi representasi awal dari data yang akan digunakan dalam proses reduksi dimensi dan visualisasi pada tahap berikutnya.

2.16 Visualisasi PCA pada Dataset Digits




Gambar tersebut menunjukkan hasil visualisasi **Principal Component Analysis (PCA)** pada dataset Digits dengan menggunakan dua komponen utama, yaitu **First principal component** pada sumbu horizontal dan **Second principal component** pada sumbu vertikal. Setiap titik pada grafik direpresentasikan menggunakan angka sesuai dengan kelas digit aslinya, yaitu 0 sampai 9. Penggunaan dua komponen utama bertujuan untuk mereduksi data berdimensi tinggi menjadi dua dimensi sehingga struktur dan persebaran data dapat diamati secara visual. Berdasarkan gambar, beberapa kelas digit terlihat membentuk kelompok tertentu, tetapi masih terdapat banyak titik dari kelas yang berbeda yang saling bertumpang tindih, terutama pada bagian tengah grafik. Hal ini menunjukkan bahwa dua komponen PCA belum sepenuhnya mampu memisahkan seluruh kelas digit secara jelas. Dalam project ini, hasil PCA kemudian dibandingkan dengan **t-SNE**, yang digunakan untuk melihat struktur data dalam ruang berdimensi rendah dan menghasilkan pemisahan kelompok yang lebih jelas secara visual dibandingkan PCA dua komponen.

2.17 Visualisasi t-SNE pada Dataset Digits



Gambar tersebut menunjukkan hasil visualisasi **t-Distributed Stochastic Neighbor Embedding (t-SNE)** pada dataset Digits yang dipetakan ke dalam dua dimensi, yaitu **t-SNE feature 0** pada sumbu horizontal dan **t-SNE feature 1** pada sumbu vertikal. Setiap titik pada grafik diberi label angka 0 sampai 9 yang menunjukkan kelas digit dari data tersebut. Dibandingkan dengan visualisasi PCA sebelumnya, hasil t-SNE pada gambar memperlihatkan bahwa kelompok digit cenderung membentuk **cluster yang lebih terpisah dan lebih jelas**, meskipun masih terdapat beberapa titik yang berdekatan atau mengalami sedikit tumpang tindih antar kelas. Visualisasi ini menunjukkan kemampuan t-SNE dalam mempertahankan struktur lokal data sehingga pola kemiripan antar gambar digit dapat terlihat lebih jelas pada ruang berdimensi rendah. Dalam project ini, t-SNE digunakan terutama sebagai **alat visualisasi struktur data nonlinear**, berbeda dengan PCA yang merupakan transformasi linear dan dapat digunakan kembali untuk melakukan transformasi pada data baru.

2.18 Proses Iterasi Algoritma K-Means Clustering



Gambar tersebut menunjukkan proses iterasi **K-Means Clustering** pada data yang terdiri dari tiga kelompok. Pada tahap **Input Data**, seluruh titik data masih belum memiliki label cluster. Selanjutnya, tahap **Initialization** menunjukkan penentuan posisi awal tiga pusat cluster (*centroid*) yang ditandai dengan simbol segitiga. Pada tahap **Assign Points**, setiap titik data diberikan ke cluster berdasarkan kedekatannya dengan pusat cluster. Setelah itu, posisi pusat cluster dihitung kembali pada tahap **Recompute Centers** berdasarkan anggota masing-masing cluster. Proses penentuan kembali anggota pada tahap **Reassign Points** dan perhitungan ulang pusat cluster dilakukan secara berulang hingga posisi cluster relatif stabil. Pada gambar terlihat bahwa setelah beberapa iterasi, tiga kelompok data dapat dipisahkan dengan jelas menjadi **Cluster 0**, **Cluster 1**, dan **Cluster 2**. Visualisasi ini menggambarkan mekanisme dasar K-Means, yaitu proses **inisialisasi centroid**, **pengelompokan titik**, **pembaruan centroid**, dan **pengulangan hingga diperoleh pengelompokan yang stabil**.

BAB III

KESIMPULAN

3.1. Kesimpulan

Berdasarkan laporan analisis eksperimental *Machine Learning* tersebut, dapat disimpulkan bahwa keberhasilan pemodelan tidak hanya bergantung pada algoritma yang digunakan, tetapi sangat dipengaruhi oleh prapemrosesan data, teknik reduksi dimensi, serta kesesuaian karakteristik algoritma dengan struktur data. Prapemrosesan data seperti *scaling* (StandardScaler, MinMaxScaler, RobustScaler, dan Normalizer) terbukti krusial untuk menyelaraskan rentang nilai fitur agar proses pembelajaran model berjalan optimal, di mana parameter *scaling* harus secara konsisten diterapkan menggunakan acuan data *training* terhadap data *testing*. Pada analisis reduksi dimensi, PCA dan NMF menunjukkan fungsi yang berbeda; PCA efektif menangkap variansi terbesar pada data linear (seperti pada representasi *Eigenfaces*), sementara NMF unggul dalam mengekstraksi komponen aditif yang bersifat non-negatif seperti pemisahan fitur wajah dan pemisahan sumber sinyal sintetis (*blind source separation*). Untuk kebutuhan visualisasi data berdimensi tinggi, teknik t-SNE terbukti lebih unggul dibanding PCA 2D dalam mempertahankan struktur lokal sehingga mampu memisahkan klaster data nonlinear secara lebih jelas, seperti yang terlihat pada dataset *Digits*. Terakhir, dalam pengelompokan tanpa label (*clustering*), pemilihan algoritma harus mempertimbangkan bentuk distribusi data; algoritma K-Means dan *Agglomerative Clustering* cocok untuk struktur konveks, sedangkan DBSCAN yang berbasis kepadatan sangat unggul dalam menangani bentuk klaster non-konveks (seperti mencapai nilai ARI 1,00 pada dataset *Two Moons*) sekaligus mengidentifikasi *noise*.